

KAMP 제조 AI 경진대회 분석 보고서

OKM 제조 설비 전력사용량 예측을 위한 데이터 전처리 및 피처 엔지니어링 계획

도메인 물리량 기반 데이터 무결성 검증, 심층 EDA 시각화 5대 인사이트,
그리고 예측 정확도 극대화를 위한 31개 파생변수 후보군 상세 명세

작성자 / 발표자 : 김정현 (LSAXMakers Data Team) | 프로젝트 브랜치 : `git checkout kjh`

핵심 키워드 : `#결측치·이상치완전정제` `#도메인대기전력검증` `#시계열자기상관성(168h)` `#31개파생변수` `#TimeSeriesSplit`

전체 회의 목차 및 진행 순서

데이터 정제부터 시각화 인사이트, 파생변수 계획까지 4단계로 논의합니다.

01

프로젝트 배경 및 데이터 개요

- **예측 목표:** OKM 제조 공장의 시간대별 전력 예측 및 180 kW 이상 피크 부하 사전 탐지
- **데이터 규모:** 2021년 1-9월 총 6,168시간 연속 시계열 및 3개 도메인 18개 원본 피쳐 특성

02

전처리 파이프라인 및 무결성 검증

- **4대 정제 성과:** 공장인원 결측(17건) 첫다운 0.0 대체, 풍속/강수 선형 보간, 7월 시간 이상치 정상 복원
- **도메인 검증:** 생산량 ↔ 인원 1:1 완벽 일치 및 무생산 시간 대기전력 Base Load(평균 46.5 kW) 입증

03

심층 EDA 5대 인사이트 & 파생변수 (핵심)

- **5대 시각화 규명:** 12시 점심 급감(-43kW), 요일x시간 조업 히트맵, 7일 주기(168h), 이봉분포, 기상 U자 곡선
- **파생변수 도출:** 각 시각화 결과와 1:1로 직결되는 5개 범주 총 31개 파생변수 풀 명세

04

모델링 검증 전략 및 향후 로드맵

- **검증 전략:** 미래 데이터 누수(Data Leakage)를 원천 차단하는 TimeSeriesSplit 4-Fold 교차검증
- **마일스톤:** LightGBM/XGBoost/CatBoost 베이스라인 벤치마킹 및 4단계 실행 로드맵

제조 설비 전력사용량 예측 과제 정의 및 원본 데이터 구조

단순 평균 전력 예측을 넘어 전력 피크(Peak Load) 위험을 사전 감지하는 것이 핵심 목표입니다.

예측 과제 정의 및 3대 핵심 난제

- **예측 대상(Target):** OKM 제조 공장의 시간대별 전력사용량 (평균 kW) 정밀 예측
- **데이터 규모:** 2021년 1월 1일 - 9월 14일 (총 6,168시간 연속 시계열 데이터셋)
- **비즈니스 가치:** 180 kW 이상 피크 초과 시 기본요금 할증 방지 및 공장 설비 과부하 예방
- **분석 난제 1 (조업 급변):** 출퇴근, 주간/야간 교대, 점심시간(12시), 주말 휴무에 따른 극심한 부하 변동
- **분석 난제 2 (기동 부하):** 주말 냉각 후 월요일 아침 설비 재가동(Start-up) 시 발생하는 초기 순간 피크
- **분석 난제 3 (기상 비선형):** 외기 온도와 습도 변화에 따른 공장 냉난방 공조 부하의 비선형 U자 반응
- **분석 전략 방향:** 단순 수치 회귀를 탈피하고 공장 물리 조업 규칙을 반영한 파생변수 주입

1. 시간 및 캘린더 영역 (8개 피쳐)

- **주요 피쳐:** 날짜(datetime), 월(m), 일(d), 요일(day: 1-7), 시간(0-23시)
- **도메인 가치:** 교대근무, 점심시간, 주말 휴무 등 규칙적 조업 주기 파악
- **데이터 품질 이슈:** 7월 시간 컬럼에 70-188 비정상값 48건 발생 (기온 곡선 검증 후 정상 복원 완료)

2. 공장 조업 및 설비 영역 (3개 피쳐)

- **주요 피쳐:** 공장인원(명), 생산량(개), 설비용량(kW - 상수값 300)
- **도메인 가치:** 제품 생산 활동 및 작업자 투입에 따른 직접적 전력 소비량 추적
- **데이터 품질 이슈:** 8월 말 인원 17시간 연속 결측 발생 (셋다운 인과성 규명 후 0.0 대체)

3. 기상 및 환경 관측 영역 (7개 피쳐)

- **주요 피쳐:** 기온(°C), 습도(%), 풍속(m/s), 강수량(mm), 일조, 일사, 적설
- **도메인 가치:** 외부 온습도 변화에 따른 공장 내부 공조/냉난방 설비 부하 추적
- **데이터 품질 이슈:** 풍속 3건, 강수량 1건 결측 발생 (대기 연속성 기반 선형 보간 적용)

4대 핵심 전처리 기법 적용 및 시계열 무결성 확보

도메인 인과관계를 철저히 검증하여 결측치 0개 및 시간 이상치 완전 복원을 달성했습니다.

1. 공장인원 결측 (17건)

- 발생 현황: 8/28 18시 - 8/29 10시 17시간 연속 결측
- 정제 조치: 해당 기간 전력 0 kW(셋다운), 생산량 0 확인 후 '0.0' 으로 대체 확정
- 도메인 근거: 전체 데이터에서 인원=0 ↔ 생산량=0 100% 성립 (휴무 기간 결측 인과성 증명)

2. 풍속·강수량 결측 (4건)


- 발생 현황: 전체 6,168시간 중 단 1-2건 국소 누락
- 정제 조치: 직전·직후 시간 관측치 기준 '선형 보간(Linear Interpolation)' 적용
- 도메인 근거: 대기 물리량의 시간적 연속성을 반영하여 왜곡 최소화

3. 시간 컬럼 이상치 (48건)

- 발생 현황: 7/13, 7/15에 70-188 비정상값 기록
- 정제 조치: 기온 일변화 곡선 100% 일치 확인 후 행 순서대로 '0-23시' 정상 재부여
- 도메인 근거: 전후 정상일과 24시간 기온 일변화 궤적이 완벽 일치 (원본은 시간_raw로 보존)

4. 전력 계산 정밀도 (float64) & 셋다운 플래그

- 정제 조치 1: 원본 평균의 반올림 오차(+/-0.5 kW) 제거를 위한 '전력_평균_실수' 신설
- 정제 조치 2: 정전/셋다운 특수 구간 마스킹을 위한 '공장_셋다운_여부' 불리언 피처 생성



생산량-인원 정비례 검증 및 비정상 섷다운 통계 분석

비생산 시간에도 대기전력(평균 46.5 kW)이 항상 흐르고 있어 0 kW 섷다운과의 물리적 차이가 입증됩니다.

1. 생산량 ↔ 인원 1:1 완벽 일치

- **통계 확인:** 전체 6,168행에서 인원=0 ↔ 생산량=0 완벽 성립
- **규명 의미:** 작업자가 없으면 생산도 없다는 도메인 물리 인과성을 산점도를 통해 통계적으로 100% 입증

2. 대기전력(Base Load)의 상시 존재


- **통계 확인:** 무생산(생산량=0) 시간에도 평균 46.5 kW (최소 17 kW) 상시 소모
- **규명 의미:** 공장이 쉬어도 조명, 통신, 보안, 기본 설비 유지를 위한 기저 부하가 24시간 흐르고 있음을 확인

3. 8/28-29 비정상 섷다운 통계적 규명

- **통계 확인:** 해당 17시간 동안은 전력이 완전 0.0 kW로 차단됨
- **규명 의미:** 단순 무생산 휴무(46.5 kW)와 달리 전원이 완전히 차단된 정전/섷다운 특수 상태임을 입증

4. 국소 확대(Local Zoom-in) 검증 의의

- **통계 확인:** 6,168행 전체 시계열 대비 36시간 및 13시간 국소 확대 대조
- **규명 의미:** 전체 시계열에서는 안 보이는 결측치 전후 연속성을 확대 플롯으로 대조하여 보간 타당성 입증




[그림 2] 생산량-인원 정비례 관계(좌) 및 생산량=0 구간 대기전력 분포(우)

인사이트 01: 시간대별 조업 주기와 점심시간 급감(Dip)

평일 12시 점심시간에 전력이 평균 43.3 kW 급감하며, 평일 주간과 주말의 전력 프로파일이 완전히 분리됩니다.


통계 분석 항목	정량적 수치	쉬운 설명 (도메인 해석)
12시 점심 급감 (Dip 현상)	11시 127.3 kW -> 12시 84.0 kW 급감 (-43.3 kW, -34.0%)	식사 시간 설비 일시정지로 급감 후 13시(123.5 kW)에 즉시 복구
주간 집중 조업	오전(08-11시) 110-127 kW 오후(13-16시) 118-124 kW	공장 정규 생산 라인이 풀가동되는 하루 중 최고 부하 집중 시간대
평일 vs 주말	평일 112.4 kW vs 주말 48.2 kW (일요일 중앙값 22.5 kW)	주말에는 생산 라인이 멈추고 기본 인프라 대기전력만 소모
생성 파생변수	산출 로직	시각화 도출 근거 및 모델링 기대 효과
점심시간여부	(시간 == 12).astype(int)	12시 43kW V자 급감 반영, 점심 과대 예측 방지
주말여부	요일.isin([6, 7]).astype(int)	평일-주말 박스플롯 분리 확인, 주말 조업 분기
조업시간대	0:심야, 1:오전, 2:점심, 3:오후, 4:야간	시간대별 계단식 전력 레벨 범주형 학습
시간_sin, cos	sin/cos(2 * pi * 시간 / 24)	23시와 00시의 원형 연속성 보존



인사이트 02: 2차원 조업 히트맵과 월요일 기동(Start-up) 부하

월-금 08-17시에 고부하가 집중되며, 특히 월요일 아침 설비 재가동 시 순간 피크 부하가 발생합니다.


통계 분석 항목	정량적 수치	쉬운 설명 (도메인 해석)
월-금 주간 블록	평일 08-17시 평균 140-170 kW (히트맵상 청색 사각 영역)	월-금 정규 조업시간대에만 140 kW 이상 고부하가 직사각형 블록으로 집중
월요일 08시 기동	월요일 08시 평균 169 kW (화-금 대비 약 35 kW 높음)	주말 동안 냉각된 설비 재가동 시 순간 시동(Start-up) 피크 발생
토요일 교대/휴무	00-06시 85-101 kW -> 07시후 30-35 kW (일요일 25-55 kW 유지)	금요일 야간 조업 잔여 후 토요일 오전부터 비가동 전환
생성 파생변수	산출 로직	시각화 도출 근거 및 모델링 기대 효과
조업집중시간여부	(평일==1) & (시간 8-11, 13-17)	140-170 kW 고부하 집중 영역 마스킹
월요일기동시간여부	(요일==1) & (시간==8)	월요일 08시 예열 피크 부하 오차 보정
공휴일여부	2021년 법정공휴일 매핑	평일 요일 공휴일의 비가동 저부하 특성 반영
영업일여부	(주말==0) & (공휴일==0)	실제 공장 정상 조업 수행일 마스터 피쳐



인사이트 03: 시계열 지연(Lag) 상관성과 7일 조업 주기

1시간 전 전력($r=0.90$)과 1주일 전 전력($r=0.74$)이 전일 동시간($r=0.37$)보다 2배 강력한 상관성을 보입니다.


통계 분석 항목	정량적 수치	쉬운 설명 (도메인 해석)
초단기 관성 (Lag 1h)	피어슨 상관계수 $r = 0.9009$ (Lag 2h 0.85, Lag 3h 0.79)	직전 1시간 전력은 현재 전력을 결정하는 가장 강력한 기준점
7일 주기 (Lag 168h)	1주일 전 상관계수 $r = 0.7397$ (전일 동시간 $r=0.37$ 대비 2배)	'월-금 가동, 토-일 휴무' 주기로 인해 1주일 전 동일 요일과 완벽 동기화
24시간 ACF 파동	24, 48, 72시간마다 규칙적 피크	하루 24시간 일변화 조업 사이클의 규칙적 반복
생성 파생변수	산출 로직	시각화 도출 근거 및 모델링 기대 효과
전력_lag1/2/3	전력(t-1), 전력(t-2), 전력(t-3)	산점도상 초강력 선형 관성($r=0.90$) 모델 주입
전력_lag168	전력(t-168) (7일 전 동일 시간)	7일 조업 주기(평일-주말 사이클) 완벽 동기화
전력_lag24	전력(t-24) (전일 동일 시간)	어제 대비 오늘의 조업 레벨 증감 추세 반영
rolling_mean/std	최근 3h, 24h 이동평균 및 표준편차	단기 노이즈 평활화 및 급격한 변동성 감지



인사이트 04: 생산 활동과 대기전력의 이봉분포(Bimodal)

공장 전력은 대기전력(20-25 kW)과 정상 가동(100-160 kW)의 완전한 2단계 계층으로 분리됩니다.


통계 분석 항목	정량적 수치	쉬운 설명 (도메인 해석)
이봉분포 (Bimodal)	대기 23 kW 피크 vs 가동 135 kW 피크 (중간값 50-80 kW 거의 없음)	단일 정규분포가 아닌 완전한 2대 기본 모드로 분리
설비 재가동 부하	정지->가동 전환 시간 평균 118.8 kW (생산량=0 구간 46.5 kW 대비 급등)	꺼진 설비를 켤 때 모터 기동 전류와 예열 부하로 순간 급증
생산량 비선형성	생산량 0개: 46kW -> 1-500개: 118kW (500개 초과: 138-160kW 완만 증가)	가동 시작 시 기본 부하(100kW) 후 생산량에 따라 계단식 증가
생성 파생변수	산출 로직	시각화 도출 근거 및 모델링 기대 효과
가동상태여부	(생산량 > 0).astype(int)	Bimodal 2대 모드(대기 vs 가동) 1차 판별
설비기동여부	(생산량_lag1==0) & (생산량>0)	라인 재가동 시 초기 기동 부하(118.8kW) 포착
인당생산량	생산량 / (공장인원 + 0.1)	작업자 투입 대비 조업 밀도 및 설비 효율 정량화
부하율_lag1	전력_평균_실수(t-1) / 설비용량(300)	설비 연속 가동률 및 정속 운전 상태 구분



인사이트 05: 기상 요인 비선형 U자 곡선과 냉난방 부하

15-20°C 쾌적 구간에서 전력이 최저이며, 불쾌지수 80 이상 혹서기에 피크 전력 위험이 4.2배 급증합니다.

통계 분석 항목	정량적 수치	쉬운 설명 (도메인 해석)
기온-전력 U자 곡선	15-20°C 최저 (공조 부하 최소) (0°C 이하 상승, 25°C 이상 급상승)	저온 난방기 및 고온 대형 냉방기 가동에 따른 전형적 비선형 U자 곡선
혹서기 피크 (DI>=80)	불쾌지수 80 이상 구간에서 175-208 kW 최대 피크 집중 (4.2배)	기온과 습도가 동반 상승하는 혹서기에 공장 냉방 공조 풀가동
습도 복합 부하	습도 80% 이상 시 냉각 부하 가중	동일 고온이라도 습도에 따라 냉각탑 및 제습 공조 추가 가동
생성 파생변수	산출 로직	시각화 도출 근거 및 모델링 기대 효과
냉방도일_CDD	$\max(\text{기온} - 22, 0)$	22°C 초과 고온 냉방 부하 선형 분리
난방도일_HDD	$\max(15 - \text{기온}, 0)$	15°C 미만 저온 난방 부하 선형 분리
불쾌지수_DI	$0.81T + 0.01RH(0.99T - 14.3) + 46.3$	온·습도 결합 복합 체감 공조 부하 수치화
혹서기_냉방경보	(불쾌지수_DI >= 80).astype(int)	180 kW 이상 최대 피크 위험 집중 학습 지원



5대 도메인 범주별 31개 파생변수 풀 종합 정리

시각화 인사이트를 통해 물리적·도메인적 타당성이 검증된 변수들로만 체계화했습니다.

도메인 범주	변수수	생성 파생변수 목록	핵심 도메인 가치 및 모델링 예측 역할
1. 시간 및 캘린더	9종	시간_sin/cos, 월_sin/cos, 주말여부, 점심시간여부, 조업시간대(5분할), 공휴일여부, 영업일여부	23-00시 순환성 보존, 12시 43kW 급감 분리, 주말 조업 중단(48kW) 및 평일 정상 조업 분기
2. 조업 스케줄·패턴	4종	조업집중시간여부, 월요일기동시간여부, 주차(week), 분기(quarter)	월-금 08-17시 고부하 마스킹, 월요일 아침 설비 예열 피크(169kW) 포착, 연간·분기별 거시 조업 흐름 반영
3. 시계열 지연·롤링	9종	전력_lag_1/2/3/24/168h, rolling_mean_3/24h, rolling_std_3/24h, 전력_diff_1h	단기 관성(Lag 1h r=0.90) 및 7일 조업주기(Lag 168h r=0.74), 가동 전환 시 변동성 감지 및 급상승 모멘텀 포착
4. 생산 및 설비 운영	5개	가동상태여부, 설비기동여부, 인당생산량, 생산량_lag1, 생산량_변화량	이봉분포(대기 23kW vs 가동 135kW) 모드 분리, 라인 재가동 시 기동 부하(118.8kW) 및 조업 밀도 반영
5. 기상 및 냉난방	6개	냉방도일(CDD), 난방도일(HDD), 불쾌지수(DI), 혹서기_냉방경보, 체감온도, 기온_변화량	15-20℃ 비선형 U자 공조 부하 선형 분리, 혹서기(DI 80 이상) 180 kW 이상 최대 피크 위험 경보

TimeSeriesSplit 4-Fold 교차검증 및 다차원 평가 체계

시계열 순서를 보존하여 미래 데이터 누수(Data Leakage)를 원천 차단하고 피크 적중률을 집중 평가합니다.

🛡️ TimeSeriesSplit 4-Fold 전진 교차검증 체계

- **데이터 누수 차단:** 무작위 셔플 시 미래 정보가 유출되므로 시간 순서를 엄격히 준수
- **[Fold 1] 간절기 전이:** 학습 1-3월 (2,160h) -> 검증 4월 (720h) | 동절기 후 봄철 전이 예측
- **[Fold 2] 냉방 진입기:** 학습 1-4월 (2,880h) -> 검증 5월 (744h) | 초여름 냉방 부하 초기 검증
- **[Fold 3] 하절기/이상치:** 학습 1-5월 (3,624h) -> 검증 6-7월 (1,464h) | 7월 복원 시간 검증
- **[Fold 4] 혹서기 피크:** 학습 1-7월 (5,088h) -> 검증 8-9월 (1,080h) | 연중 최대 혹서기 피크 종합 평가
- **검증 신뢰도 효과:** 과거 데이터를 점진적으로 누적하며 항상 미확인 미래 구간을 정밀 평가

🎯 평가 지표 체계 & 3대 베이스라인 알고리즘

- **RMSE (최우선 최적화):** 피크 부하 구간의 큰 오차에 높은 패널티를 부여하는 핵심 지표
- **MAE (직관적 오차):** 실제 전력과 예측 전력 간의 평균 절대 오차 (단위: kW)
- **MAPE (백분율 오차):** 전체 전력 대비 백분율 오차율 (공장 운영진 보고용, 10% 이내 목표)
- **피크 적중률 (Recall):** 180 kW 이상 최대 피크 위험 시간대 사전 경보 성공률 ($y \geq 180\text{kW}$)
- **LightGBM:** 대용량 테이블 시계열 최고 속도, 비선형 변수 상호작용 학습 우수
- **XGBoost:** 강력한 정규화 패널티(L1/L2)로 이상치 및 결측 구간 안정적 수렴
- **CatBoost:** 조업시간대, 요일 등 범주형 변수를 타깃 인코딩 손실 없이 최적 처리
- **앙상블 블렌딩:** 3대 모델 가중치 결합으로 단일 모델의 극단적 오차 상호 보완

기획 완료 후 실제 구현 및 모델링 4단계 타임라인

팀원 회의 피드백을 수렴하여 파생변수 생성부터 모델 벤치마킹까지 단계별로 수행합니다.

[Phase 1] 전처리 및 파생변수 기획 [완료]

- 수행 내용: 6,168시간 결측치 0개 및 시간 이상치 완전 정제, 5대 심층 EDA 플롯 완료
- 주요 산출물: reports/feature_engineering_plan.md, figures/fe_0*.png, 발표용 보고서(PDF/PPTX)
- 현재 상태: GitHub kjh 브랜치 공유 및 팀 피드백 수렴 단계

[Phase 2] 파생변수 파이프라인 구현 [차기 진행]

- 수행 내용: 팀 회의 피드백 기반 31개 파생변수 우선순위 확정 및 클래스 기반 파이프라인 구축
- 주요 산출물: src/features.py 모듈 작성, notebooks/kjh/03_feature_engineering_eda.ipynb
- 목표 일정: 내일 회의 직후 2단계 모듈 구현 착수

[Phase 3] 머신러닝 베이스라인 구축 [대기]

- 수행 내용: TimeSeriesSplit 4-Fold 교차검증 연결, LightGBM/XGBoost/CatBoost 성능 벤치마킹
- 주요 산출물: src/models/baseline.py, reports/baseline_performance.csv (RMSE/MAE 비교표)
- 검증 목표: 원본 피쳐 대비 31개 파생변수 투입 후 예측 오차 감소율 정량 검증

[Phase 4] 피크 분석 및 모델 고도화 [대기]

- 수행 내용: SHAP 및 Feature Importance 분석, 180 kW 이상 최대 피크 발생 조건 역추적 규명
- 주요 산출물: reports/peak_risk_analysis.md, final_submission_pipeline.py 최종 제출 파이프라인
- 최종 목표: KAMP 경진대회 제출용 앙상블 모델 완성 및 피크 부하 사전 경보 시스템 수립

경청해 주셔서 감사합니다

Q & A 및 팀원 피드백 논의

안건 1. 파생변수 우선순위 확정

- 논의 내용: 31개 후보 변수 중 1차 베이스라인 모델에 우선 투입할 핵심 피처 선정 및 추가 아이디어
- 목표 산출물: 우선 투입 파생변수 목록 확정 및 제외 변수 합의

안건 2. 지연 피처(Lag) 윈도우 합의

- 논의 내용: Lag 168h(1주일) 및 Lag 24h(전일) 생성 시 발생하는 초기 결측 구간 처리 방식 확정
- 목표 산출물: 초기 결측 행 마스킹 또는 제거 기준 합의

안건 3. 평가 지표 가중치 결정

- 논의 내용: 전체 평균 오차(MAE/RMSE)와 최대 피크 적중률(Peak Recall) 중 최우선 최적화 지표 확정
- 목표 산출물: 모델 튜닝 목적함수 및 손실 가중치 합의

안건 4. 모델링 역할 분담

- 논의 내용: LightGBM, XGBoost, CatBoost 모델별 파라미터 튜닝 및 Feature Importance 분석 파트너링
- 목표 산출물: 팀원별 머신러닝 알고리즘 R&R 분담 확정